

Wikipedia Article Analysis

TP Diseño

Nombre	Padrón	Email
Bautista Lynch	108791	blynch@fi.uba.ar
Joaquín Batemarco	110222	jbatemarco@fi.uba.ar
Benicio Braunstein	110126	bbraunstein@fi.uba.ar

Alcance **3**
Descripción general de la arquitectura **3**
Escenarios **3**
Vista Lógica **4**
Componentes principales 4
Componentes por grupo funcional 5
Imágenes y URLs (Q1 y Q2) 5
Palabras únicas (Q3) 5
Top de palabras (Q4) 5
Promedio y filtrado (Q5) 5
Relaciones entre componentes 5
Vista de Desarrollo **5**
Vista de Procesos **7**
Requerimiento 1 8
Requerimiento 2 9
Requerimiento 3 10
Requerimiento 4 11
Requerimiento 5 12
Vista Física **14**
Tamaño y rendimiento **17**
Tabla de contribuciones **17**

Alcance

Se diseña un sistema distribuido para analizar conjuntos de artículos de Wikipedia escritos en inglés y francés. Cada cliente envía sus artículos y recibe los resultados correspondientes a cinco consultas:

1. Url y fecha de modificación para artículos escritos en inglés hasta 2020 inclusive.
2. Nombre, url e imágen (bytes) de artículos escritos hasta 2020 inclusive que incluyan “biography” o “biographie” entre sus secciones.
3. Listado de palabras únicas compartidas entre cualquier artículo escrito en inglés y cualquier artículo escrito en francés.
4. Pares (palabra, cantidad) del top 20 palabras más utilizadas entre todos los abstracts. Dentro de un mismo abstract las palabras se cuentan una sola vez y las palabras triviales (stopwords) se excluyen del top.
5. Url y cantidad de palabras de abstract para los artículos escritos a partir del 2021 cuya cantidad de palabras en el abstract sea superior al promedio de palabras de abstract de todos los artículos escritos hasta el 2020 inclusive. Se aplica el mismo criterio para contabilizar palabras que la query anterior.

El sistema acepta múltiples clientes manteniendo aislados sus datos y consultas. Se contempla la distribución de procesamiento entre varias máquinas y la incorporación de réplicas para poder procesar grandes volúmenes de información.

Descripción general de la arquitectura

Tenemos puntos de entrada y salida diferentes para la comunicación con los clientes. El punto de entrada o “Gateway” se encarga de descartar las columnas que no se utilizan en el resto del programa antes de enviar los mensajes a las respectivas colas.

Para optimizar el sistema frente a la cantidad de clientes y el volumen de datos por cada uno, nuestra solución presenta diferentes componentes. Cada uno se encarga de aplicar una función a los datos, lo que permite distribuir el cómputo.

Por otro lado, existen también encargados de persistir los datos recibidos a disco con el fin de evitar mantener en memoria ram todo el volumen de información mientras se procesa el flujo de datos. Una vez finalizada la consulta del cliente, ya puede liberarse ese espacio.

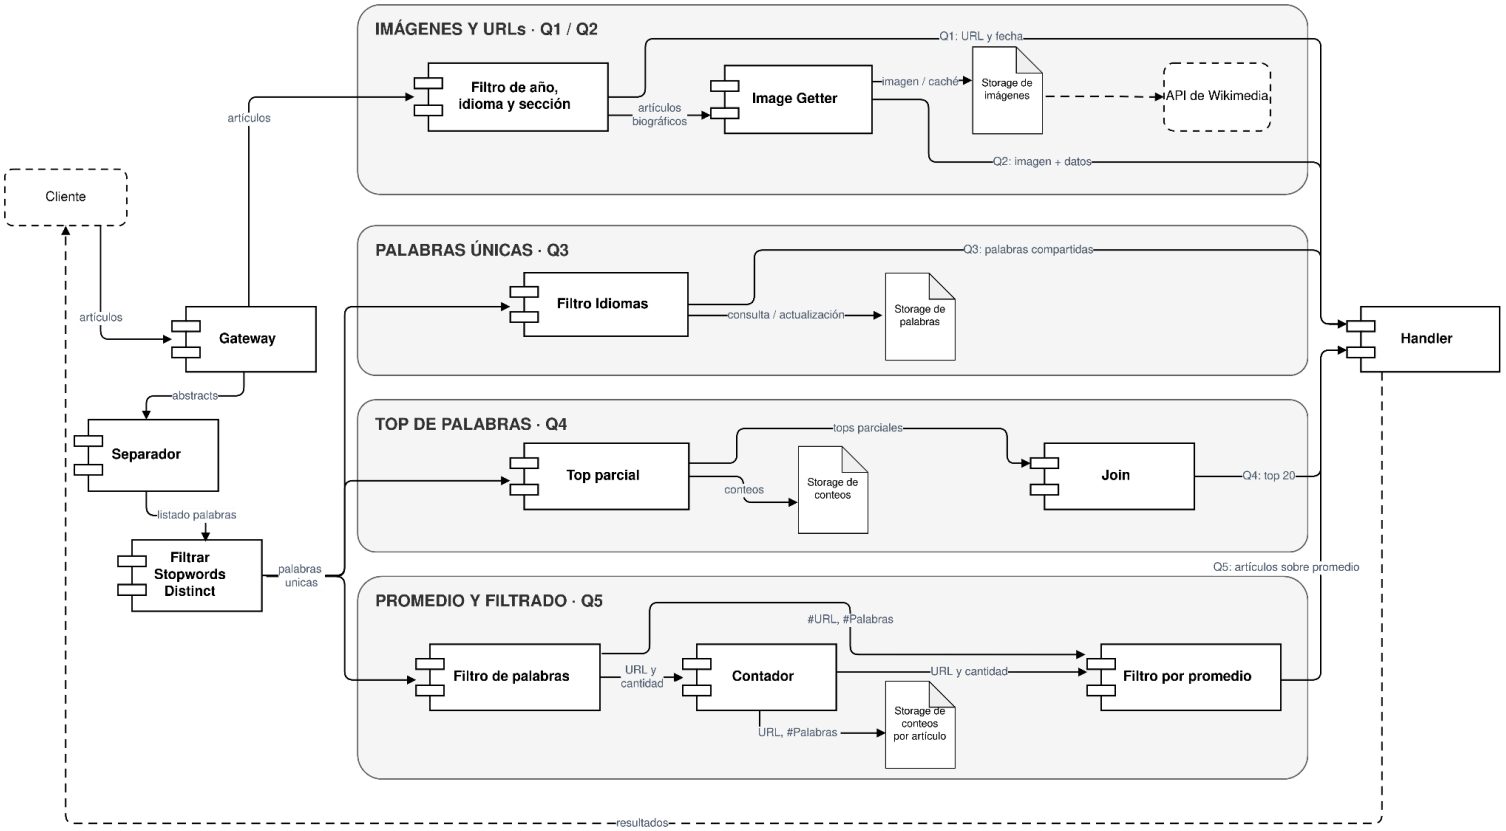
Escenarios

El único actor del sistema es el **cliente**. Cada cliente envía su conjunto de artículos y recibe los resultados de las cinco consultas, sin interferir con los demás clientes. El escenario que tenemos es el único requisito que hace el cliente; establecido en el alcance. Mientras el cliente sigue enviando datos, las consultas que ya pueden resolverse van devolviendo resultados. Al terminar el envío, el cliente informa el fin de su entrada y esa señal se propaga por todas las etapas hasta cerrar la respuesta.

Vista Lógica

La vista lógica presenta la organización funcional del sistema, identificando sus componentes principales, las responsabilidades de cada uno y las relaciones que permiten satisfacer los requerimientos.

En la Figura 1 se presenta el diagrama de componentes del sistema. La arquitectura se organiza en componentes de entrada y salida, procesamiento compartido y cuatro grupos funcionales que permiten resolver las cinco consultas solicitadas.



[Figura 1] Diagrama de componentes

Componentes principales

Gateway: recibe los artículos enviados por los clientes, identifica la ejecución, selecciona los campos necesarios y distribuye los datos hacia los componentes correspondientes.

Separador / Stopwords: procesa los abstracts, separando y normalizando las palabras, eliminando las palabras triviales (stopwords) y asegurando su unicidad por artículo.

Handler: centraliza los resultados de las distintas consultas y los entrega progresivamente al cliente, notificando la finalización del procesamiento cuando corresponde.

Componentes por grupo funcional

Imágenes y URLs (Q1 y Q2)

Este grupo se encarga de filtrar los artículos según su año, idioma y secciones. Para la primera consulta, el filtro envía al Handler la URL y la fecha de modificación de los artículos que cumplen las condiciones. Para la segunda, el componente Image Getter obtiene las imágenes desde el almacenamiento local o, si no están disponibles, mediante la API de Wikimedia (externa al sistema).

Palabras únicas (Q3)

El Filtro Idiomas identifica las palabras compartidas entre los abstracts escritos en inglés y francés. Para ello, utiliza un almacenamiento local que registra las palabras y los idiomas en los que aparecen, permitiendo detectar y enviar al Handler aquellas presentes en ambos idiomas.

Top de palabras (Q4)

El componente Top Parcial acumula las apariciones de cada palabra y calcula los resultados parciales. Posteriormente, el componente Join consolida estos resultados para obtener las 20 palabras más utilizadas globalmente, que son enviadas al Handler.

Promedio y filtrado (Q5)

Este grupo está compuesto por el Filtro de palabras, el Contador y el Filtro por promedio. El primero prepara los datos necesarios para el conteo, mientras que el Contador calcula la cantidad de palabras por artículo y el promedio correspondiente a los artículos escritos hasta 2020 inclusive. Finalmente, el Filtro por promedio selecciona los artículos posteriores a 2020 cuya cantidad de palabras supera dicho valor.

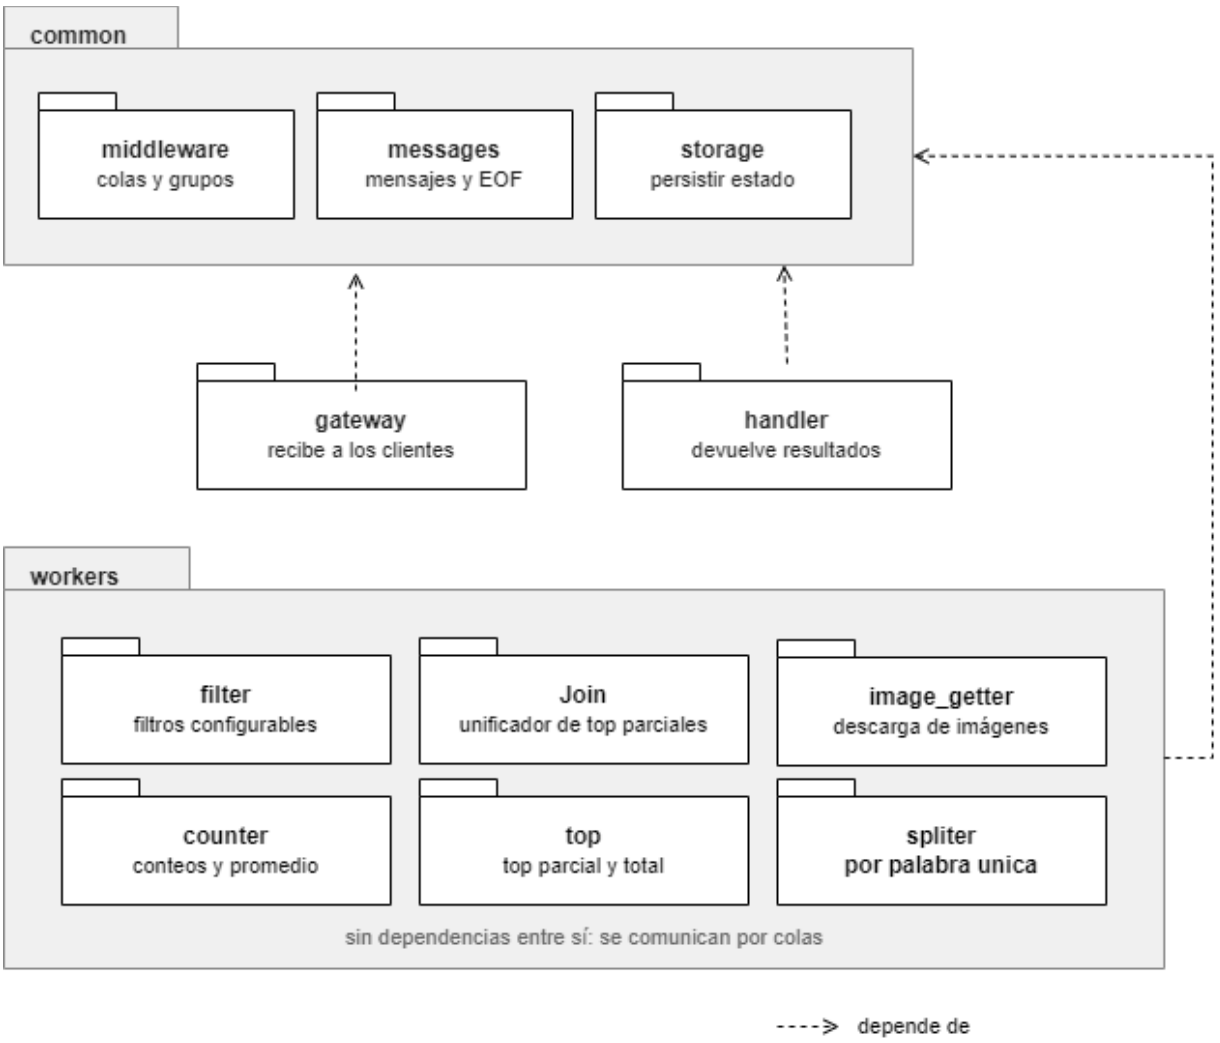
Relaciones entre componentes

Los componentes se comunican mediante el intercambio de mensajes, manteniendo separadas sus responsabilidades. Los resultados de las distintas consultas convergen en el Handler, mientras que los componentes que requieren conservar información utilizan mecanismos de almacenamiento local.

Esta organización favorece el desacoplamiento entre las etapas de procesamiento y permite reutilizar componentes compartidos entre diferentes consultas.

Vista de Desarrollo

Describe la organización del sistema desde la perspectiva de su implementación, mostrando cómo se estructura el código fuente en módulos, paquetes y componentes de software, así como las dependencias entre ellos.



[Figura 2] Diagrama de paquetes

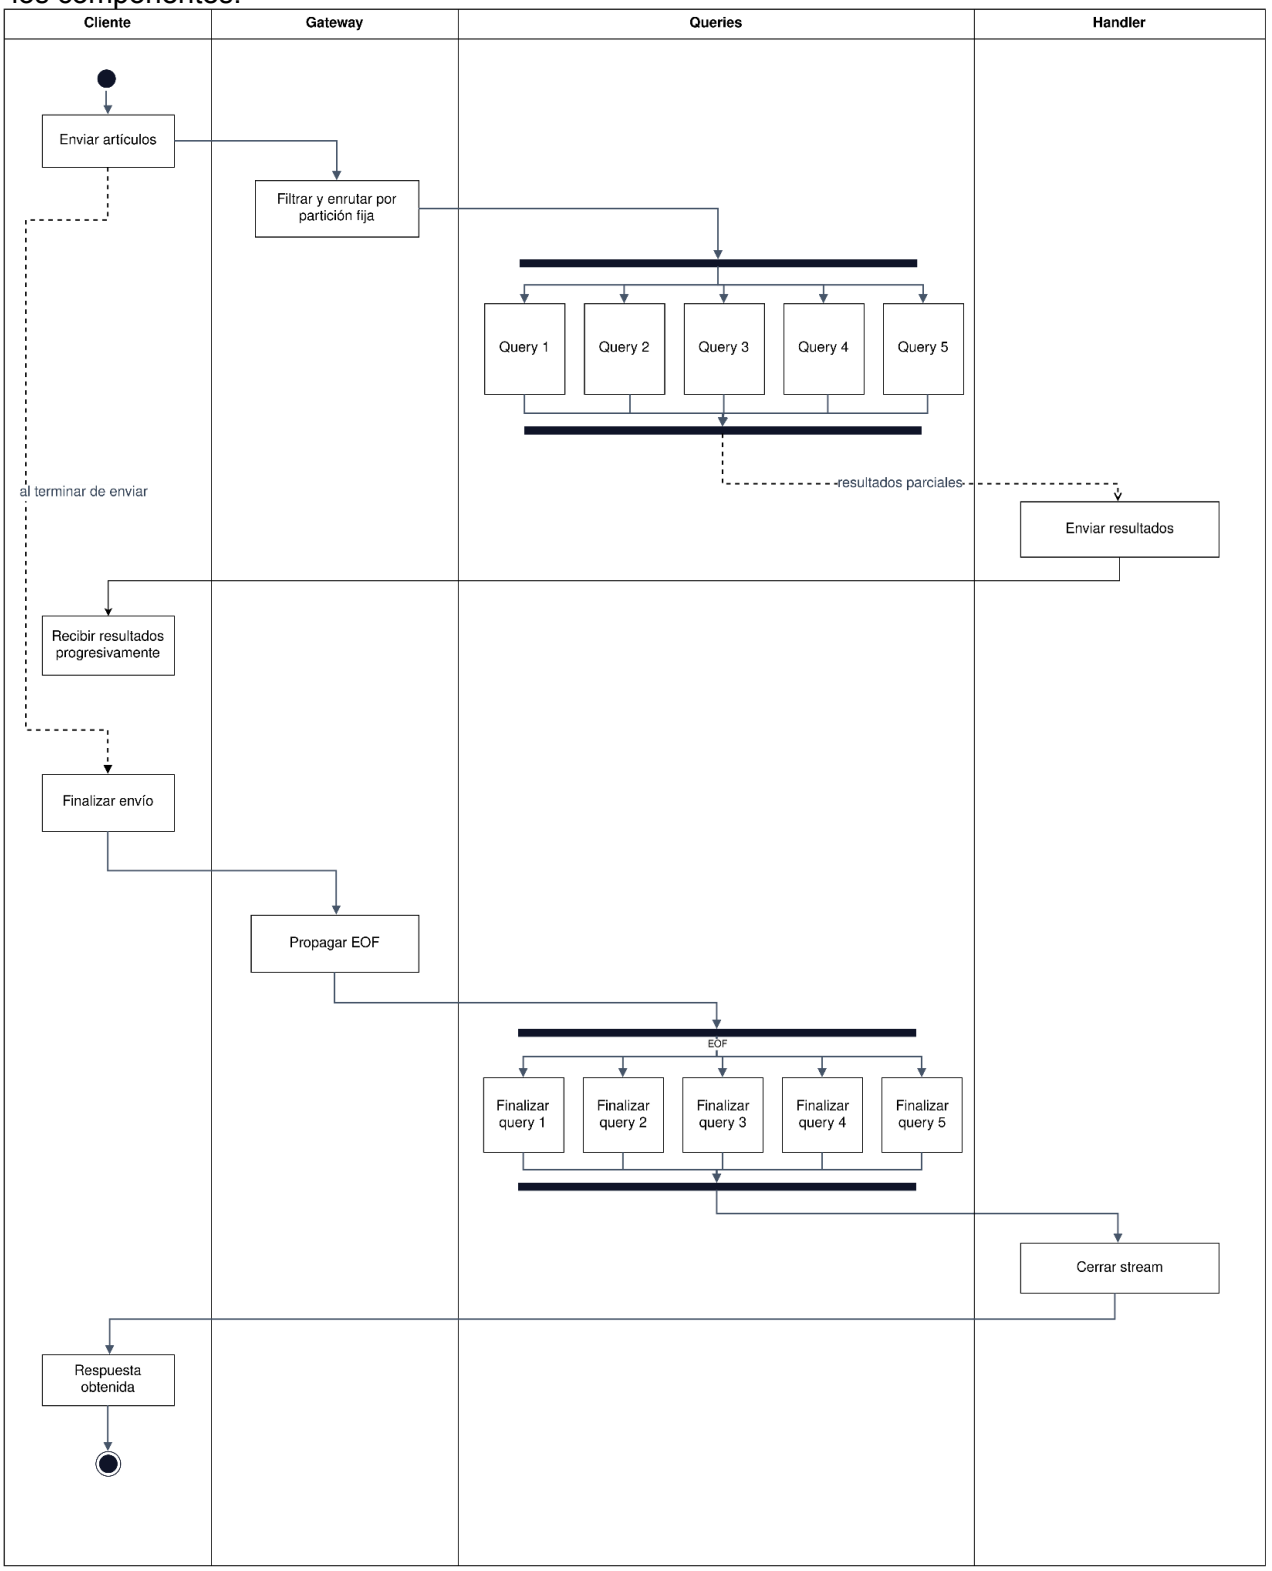
La vista de desarrollo organiza el código en tres grupos de paquetes. El paquete common contiene lo que comparte todo el sistema: middleware (abstracción de colas y grupos de comunicación sobre el broker), messages (formato de los mensajes, incluyendo ClientID y EOF) y storage (persistencia del estado). Los procesos de entrada y salida, gateway (recibe a los clientes y reparte los datos) y handler (devuelve los resultados), dependen únicamente de common.

El paquete workers agrupa los tipos de nodo que procesan las consultas: filter (filtros configurables por año, idioma y sección), image_getter (descarga de imágenes), counter (conteos y promedio), top (cálculo del top parcial) y join (calcula el top 20 final). Todos dependen de common, pero no dependen entre sí: se comunican exclusivamente a través de colas. Por eso se puede agregar, quitar o escalar un tipo de nodo sin modificar a los demás.

Esta separación permite escalar horizontalmente cada worker de forma independiente. El acoplamiento queda concentrado en common, que define el contrato de comunicación.

Vista de Procesos

Esta vista describe el comportamiento dinámico del sistema, mostrando cómo interactúan y se coordinan los distintos procesos durante su ejecución. Permite representar aspectos como la concurrencia, la comunicación, la sincronización y la distribución de responsabilidades entre los componentes.



[Figura 3] Diagrama de actividades mostrando el flujo general del procesamiento del sistema

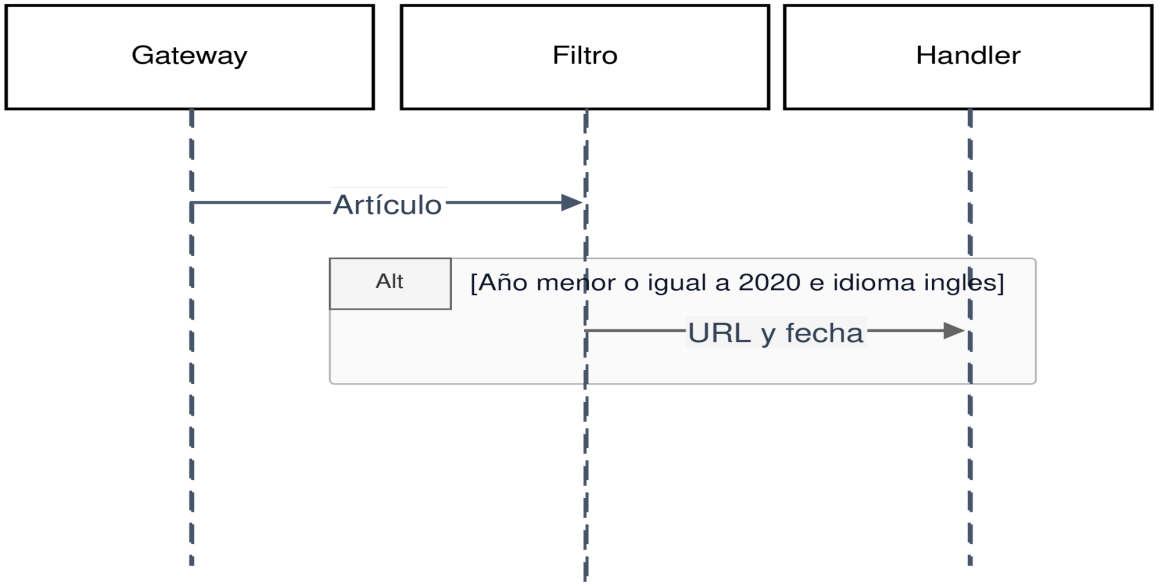
Se presenta la Figura *3*, con el flujo general de procesamiento del sistema, mostrando la interacción entre el Cliente, Gateway, Workers y Handler, así como la ejecución concurrente de las consultas.

El proceso comienza cuando el Cliente envía los artículos al Gateway, encargado de filtrarlos y distribuirlos. Posteriormente, se procesan las cinco consultas sobre los artículos en paralelo y envían sus resultados parciales al Handler, que los transmite progresivamente al Cliente mediante un stream de respuestas.

Una vez finalizado el envío de artículos, el Cliente notifica su finalización y el Gateway propaga la señal de fin de flujo (EOF) a las consultas. Esta señal desencadena la finalización de los procesamientos pendientes y la emisión de los resultados restantes.

Finalmente, cuando todas las consultas han terminado, el Handler cierra el stream de respuestas y el Cliente recibe la confirmación de finalización del procesamiento.

Requerimiento 1



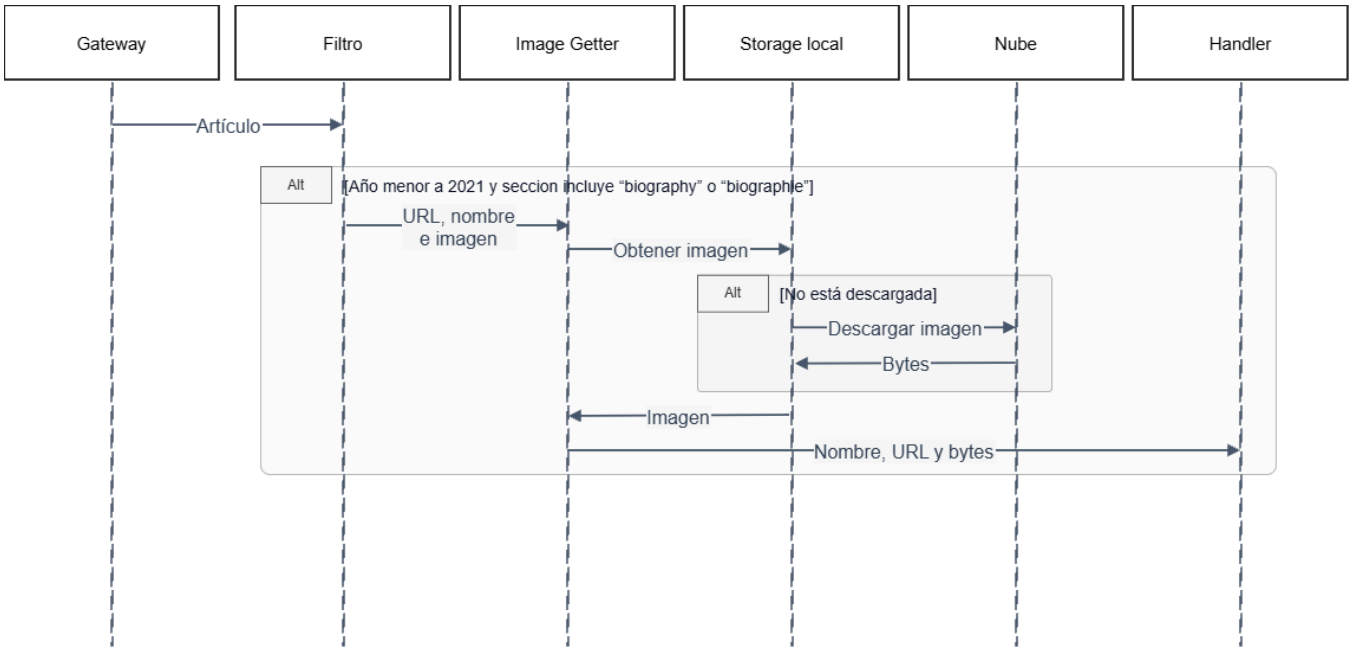
[Figura 4] Diagrama de secuencia de query uno

Se solicita obtener la url y la fecha de modificación para los artículos escritos en inglés hasta 2020 inclusive. En la Figura *4* se presenta la interacción entre los componentes “Gateway”, “Filtro” y “Handler” para resolver el requerimiento.

La secuencia comienza cuando el Gateway envía un artículo al componente Filtro, responsable de evaluar si cumple con las condiciones establecidas: estar escrito en inglés y corresponder a un año menor o igual a 2020.

En caso de cumplirse ambas condiciones, el Filtro provee al Handler la url y la fecha de modificación del artículo, que constituyen los datos requeridos por la consulta.

Requerimiento 2



[Figura 5] Diagrama de secuencia de query dos

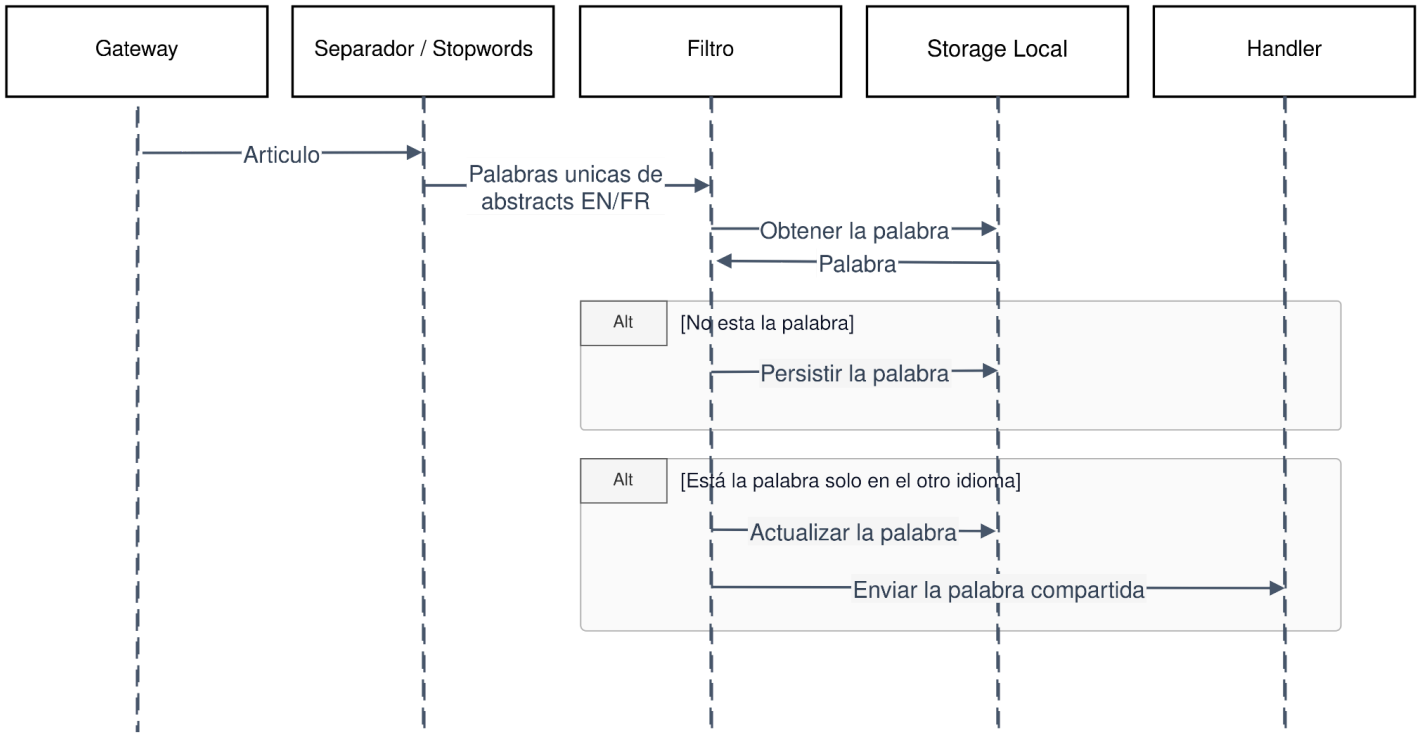
2020 inclusive que incluyan “biography” o “biographie” entre sus secciones. En la Figura *5* se presenta la interacción entre los componentes “Gateway”, “Filtro”, “Image Getter”, “Storage local”, “Nube” y “Handler” para resolver el requerimiento.

La secuencia comienza cuando el Gateway envía un artículo al componente Filtro, responsable de evaluar si cumple con las condiciones establecidas: corresponder a un año menor o igual a 2020 y contener alguna de las secciones indicadas.

En caso de cumplirse ambas condiciones, el Filtro envía la URL, el nombre y la referencia de la imagen al Image Getter, que solicita la imagen al almacenamiento local. Si no se encuentra descargada, se obtiene desde la Nube y se almacena localmente.

Finalmente, el Image Getter envía el nombre y los bytes de la imagen al Handler.

Requerimiento 3



[Figura 6] Diagrama de secuencia de query tres

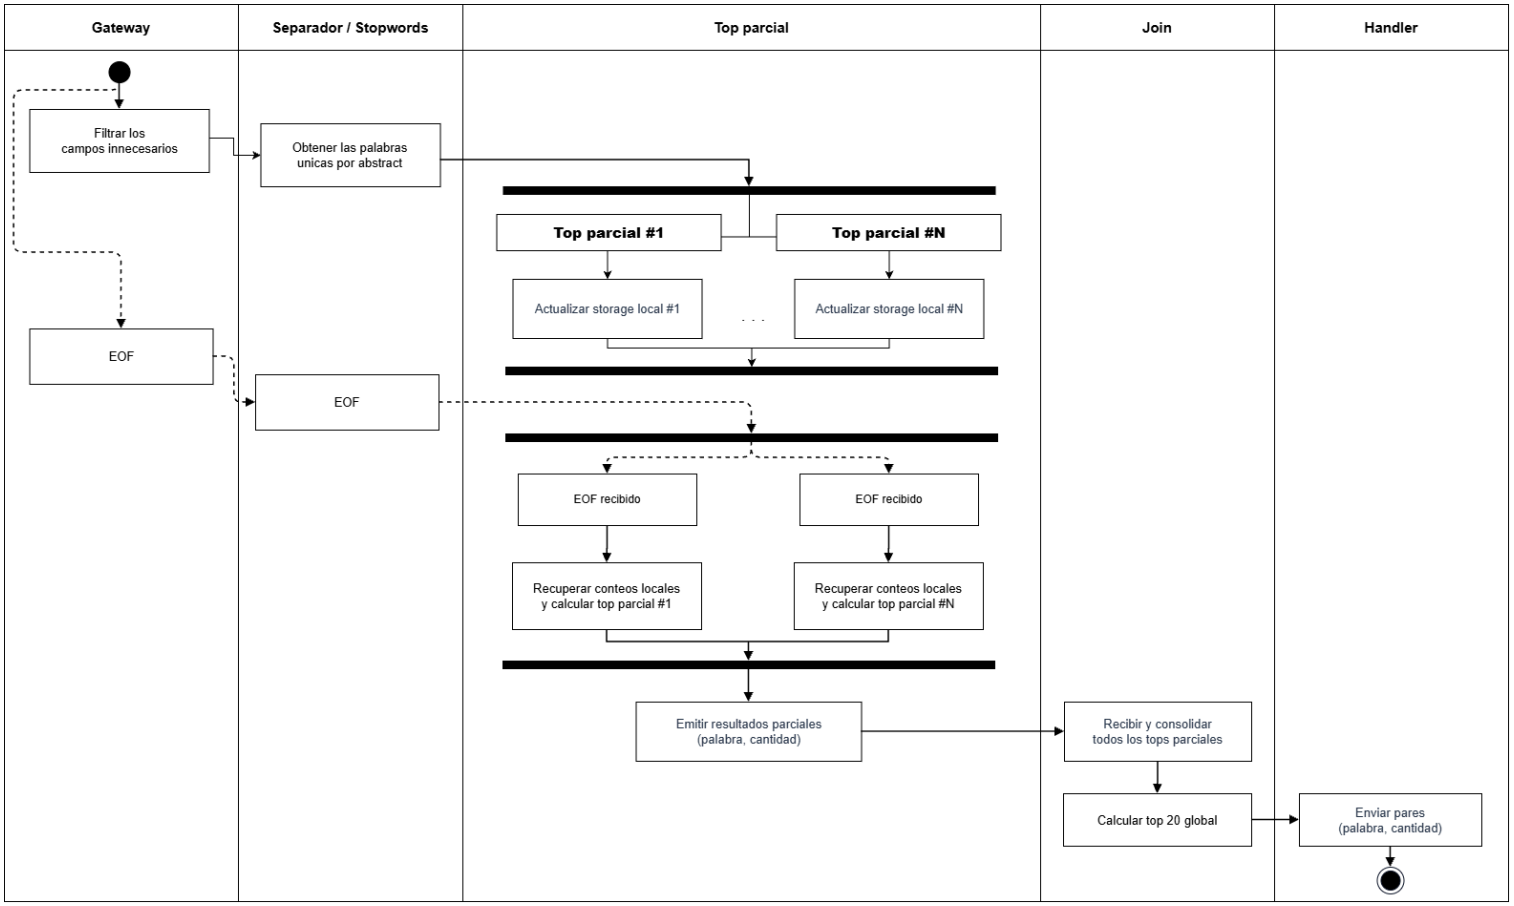
Se solicita obtener el listado de palabras únicas compartidas entre cualquier artículo escrito en inglés y cualquier artículo escrito en francés. En la *figura 6* se presenta la interacción entre los componentes “Gateway”, “Separador / Stopwords”, “Filtro”, “Storage Local” y “Handler” para resolver el requerimiento.

La secuencia comienza cuando el Gateway envía un artículo al componente Separador / Stopwords, responsable de extraer las palabras únicas de los abstracts en inglés y francés, eliminando las palabras vacías (stopwords).

Posteriormente, el Filtro consulta cada palabra en el almacenamiento local. Si no existe, la persiste junto con su idioma de origen. Si la palabra ya existe, pero únicamente está registrada en otro idioma, actualiza su información para indicar que es compartida entre ambos idiomas.

Finalmente, cuando se identifica una palabra compartida, el Filtro la envía al Handler para incorporar al resultado de la consulta.

Requerimiento 4



[Figura 7] Diagrama de actividades de query cuatro

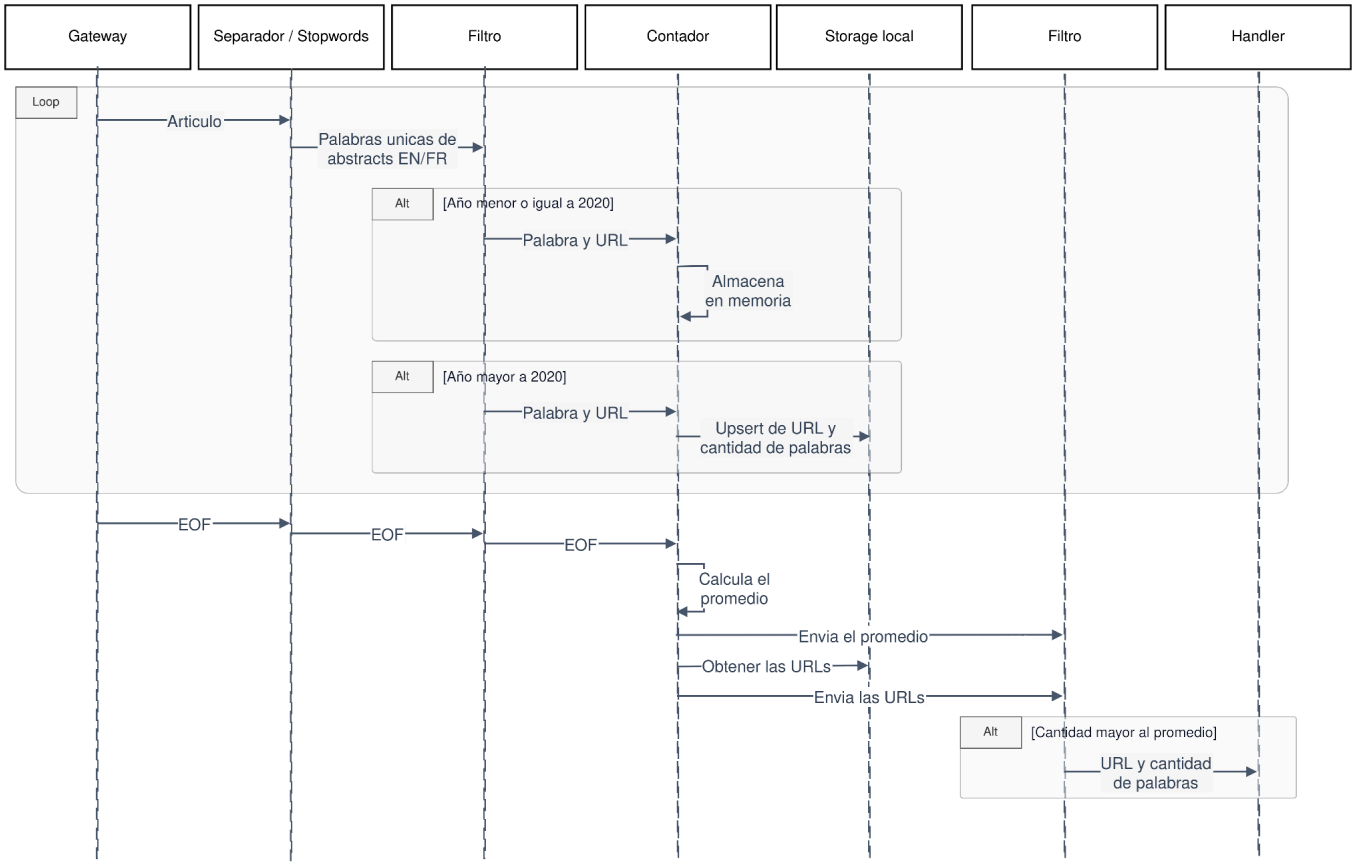
Se solicita obtener los pares (palabra, cantidad) del top 20 de palabras más utilizadas entre todos los abstracts, contabilizando cada palabra una sola vez por abstract y excluyendo las palabras triviales (stopwords). En la *Figura 7* se presenta el flujo de actividades entre los componentes “Separador / Stopwords”, “Top parcial”, “Join” y “Handler” para resolver el requerimiento.

El proceso comienza con la tokenización de los abstracts y la eliminación de las palabras triviales, obteniendo las palabras únicas de cada uno. Estas se almacenan y, una vez recibida la señal de fin de flujo (EOF), se inicia el cálculo de los resultados parciales en paralelo.

Posteriormente, los resultados de cada nodo se consolidan en el componente Join, encargado de calcular el top 20 global a partir de los conteos parciales.

Finalmente, el resultado se envía al Handler en forma de pares (palabra, cantidad).

Requerimiento 5

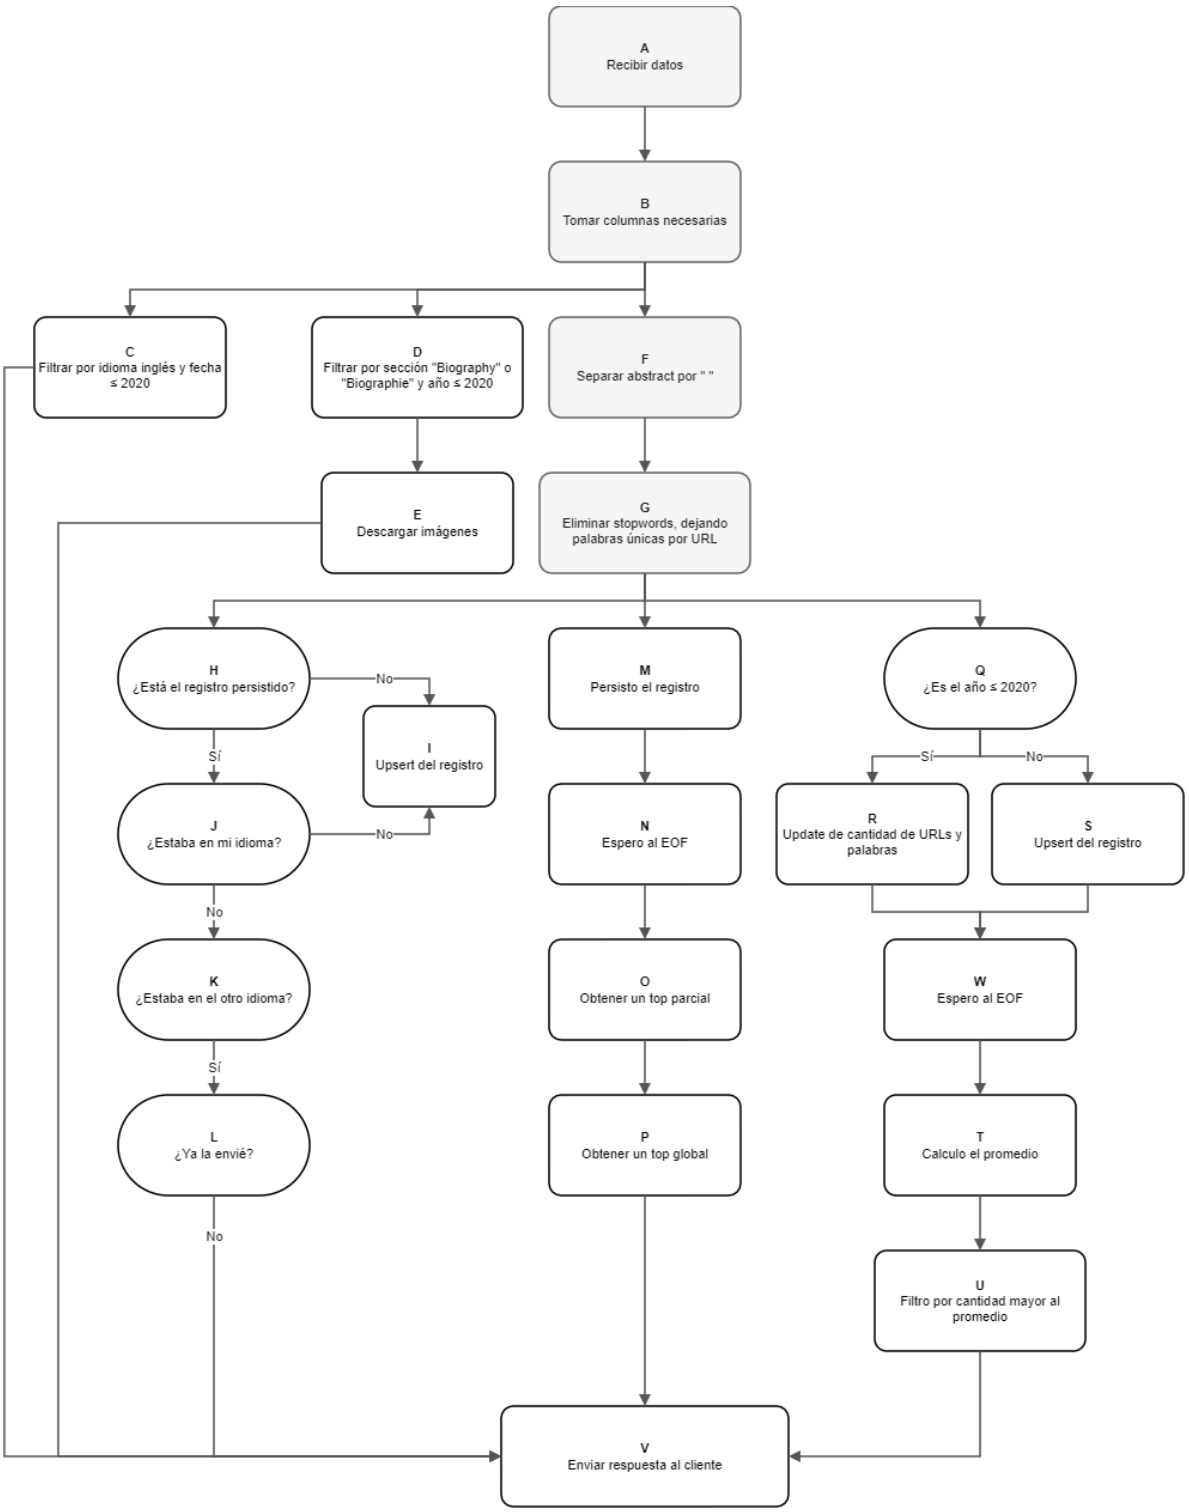


[Figura 8] Diagrama de secuencia de query cinco

Se solicita obtener la URL y la cantidad de palabras del abstract de los artículos escritos a partir de 2021 cuya cantidad de palabras supere el promedio de los artículos escritos hasta 2020 inclusive, aplicando el mismo criterio de contabilización que en el requerimiento anterior. En la Figura *8* se presenta la interacción entre los componentes “Gateway”, “Separador / Stopwords”, “Filtro”, “Contador”, “Storage local” y “Handler” para resolver el requerimiento.

La secuencia comienza cuando el Gateway envía los artículos al componente Separador / Stopwords, encargado de extraer las palabras únicas de cada abstract y eliminar las palabras triviales. Posteriormente, el Filtro clasifica los artículos según su año de publicación. Para aquellos escritos hasta 2020 inclusive, el Contador almacena en memoria la cantidad de palabras, mientras que para los posteriores a 2020 persiste la URL y la cantidad de palabras en el almacenamiento local.

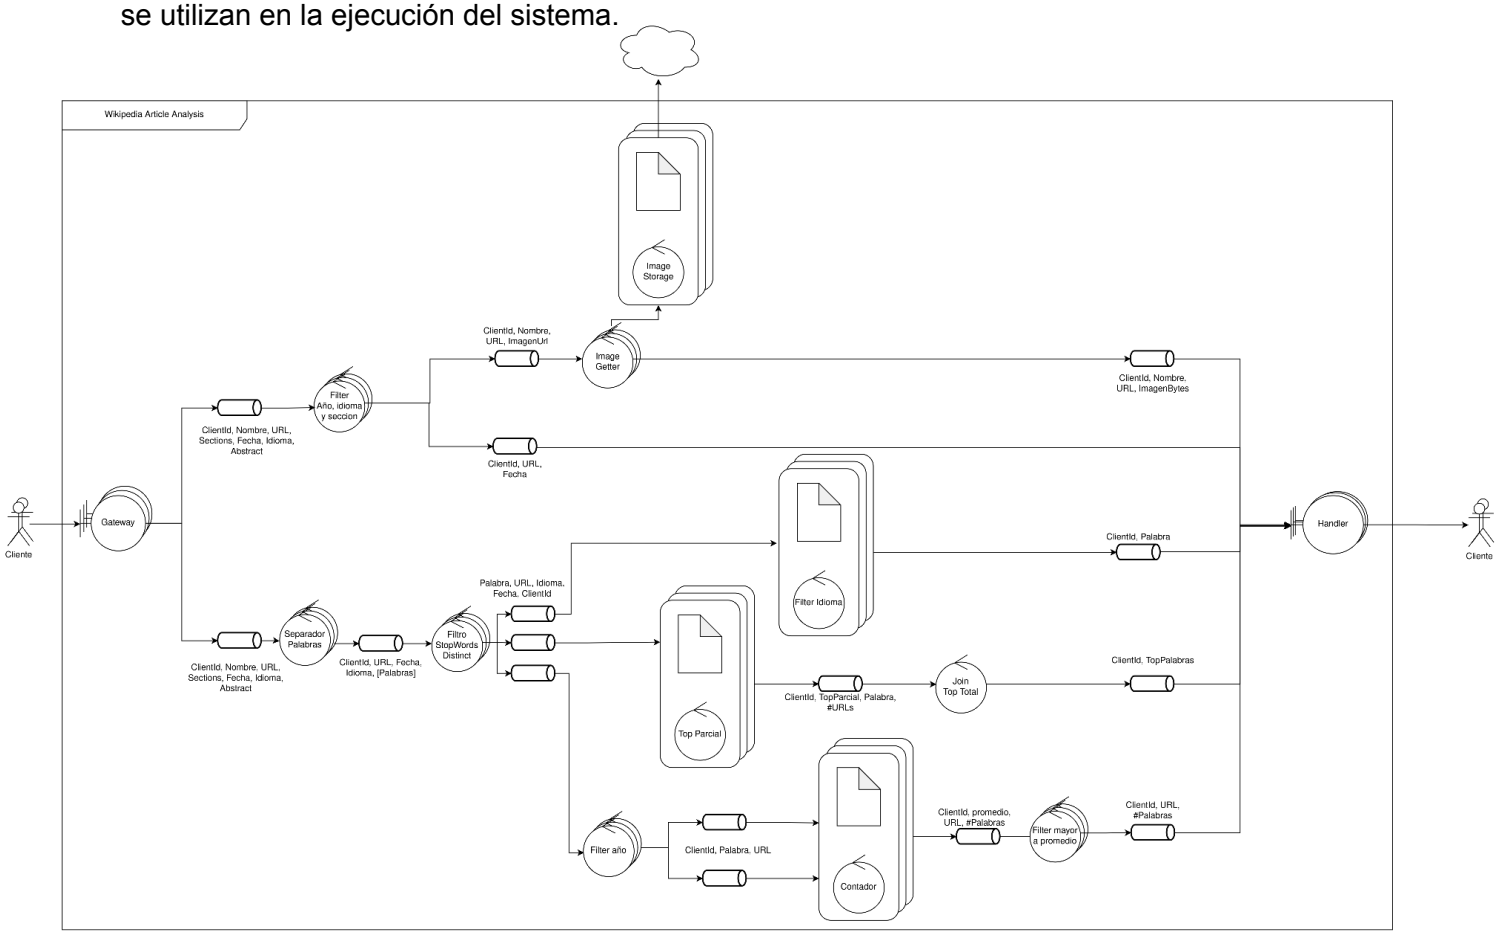
Una vez recibida la señal de fin de flujo (EOF), el Contador calcula el promedio de palabras de los artículos hasta 2020 y recupera las URLs almacenadas. Finalmente, se filtran los artículos cuya cantidad de palabras supera dicho promedio y se envían al Handler los pares (URL, cantidad de palabras) correspondientes.



[Figura 9] DAG lógico del sistema

Vista Física

Describe cómo se distribuyen y despliegan los componentes del sistema sobre la infraestructura física o virtual, identificando los nodos de ejecución, sus conexiones y la asignación de los componentes a cada nodo.
En la vista física o despliegue se presenta la organización de las instancias y los recursos que se utilizan en la ejecución del sistema.



[Figura 10] Diagrama de robustez del sistema Wikipedia Article Analysis

En la figura 10 se delimita el sistema de Wikipedia Article Analysis que se diseñó para este trabajo. Se ven los puntos de entrada y salida del sistema que se brindan al cliente, desde el gateway y el handler.

Los canales representados entre componentes indican los mensajes intercambiados. Los mismos se crearán con el uso del middleware orientado a mensajes, RabbitMQ, haciendo uso de las queues y exchanges que provee su interfaz.

Los controladores internos leen de uno de estos canales, procesan y transforman los datos de entrada y envían el resultado por otro canal. Estos controladores tienen “N” instancias, como variable de entorno configurable para permitir la escalabilidad de los componentes de forma independiente.

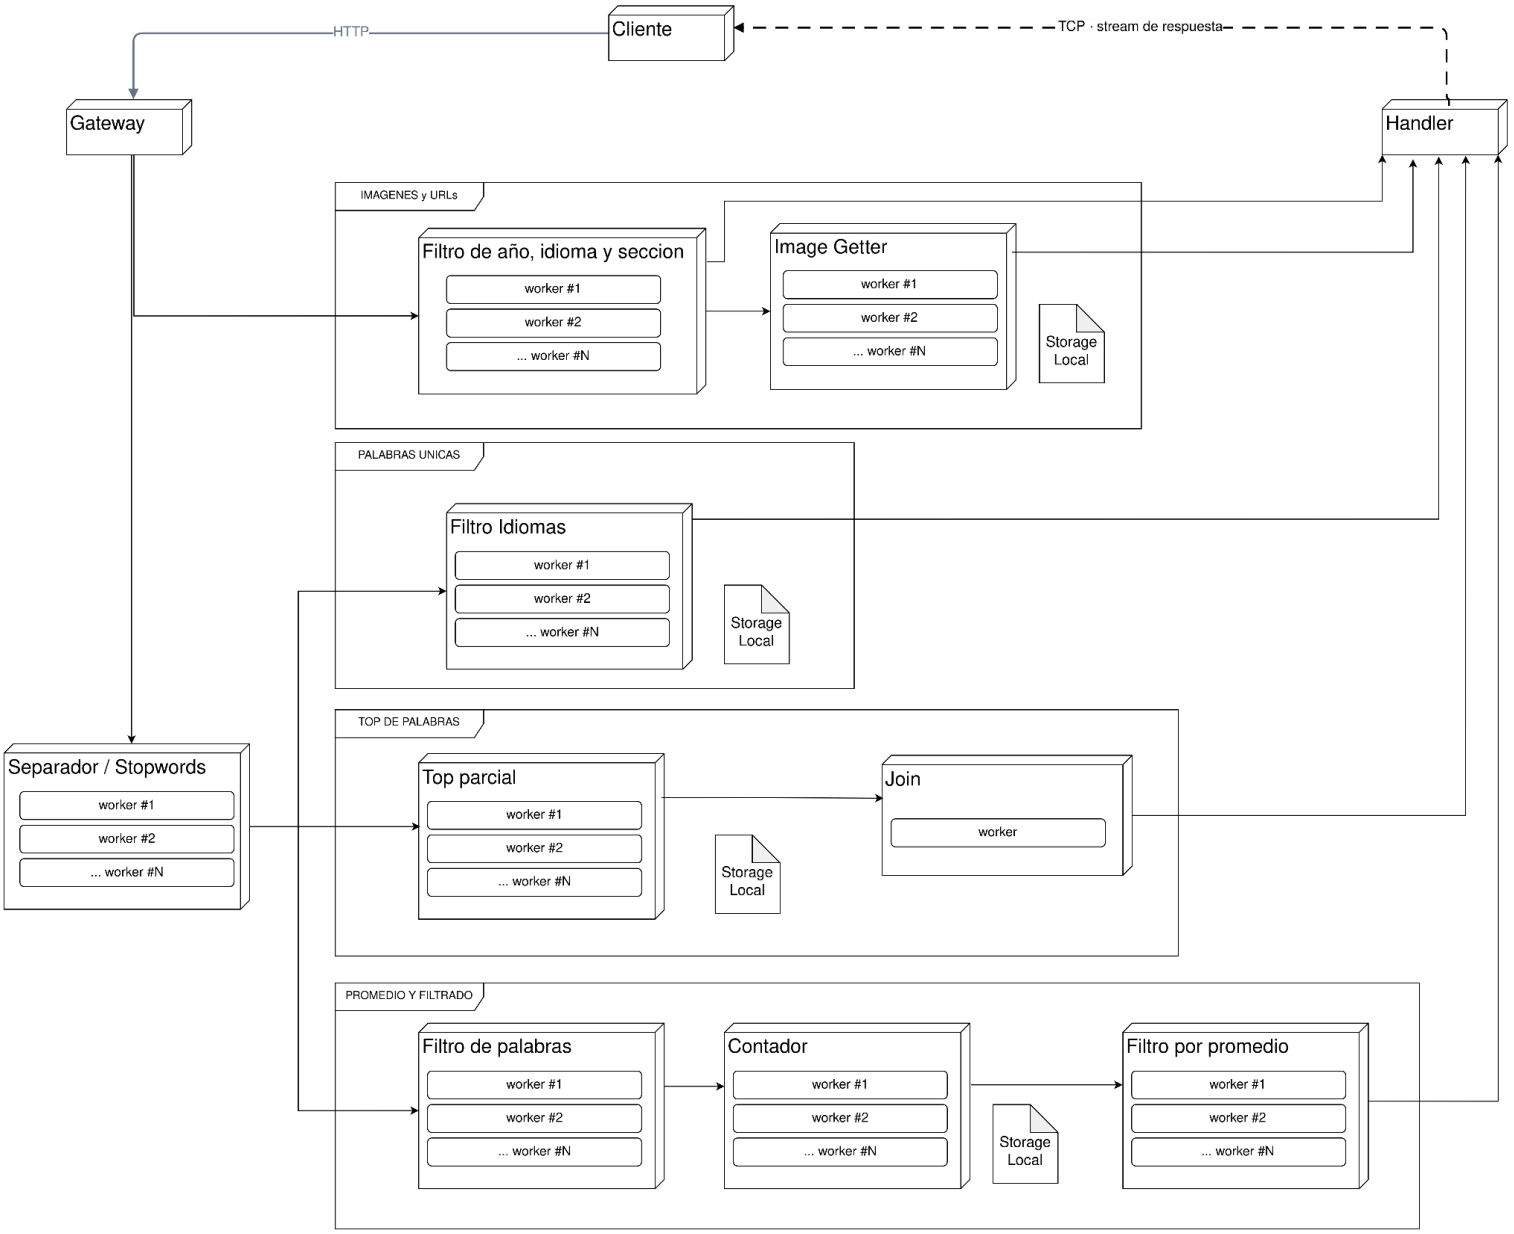
Image Getter utiliza el Image Storage distribuido para obtener las imágenes. La conexión a la nube representa el acceso a la API externa de Wikimedia. El storage además persiste algunas imágenes como Caché para poder contestar con mayor velocidad en caso de un hit.

Desde el Separador Palabras y Filtro StopWords Distinct se transforman los requests por URL en diferentes mensajes por cada palabra. Estos mensajes son los que se distribuyen para el procesamiento de las queries 3, 4 y 5.

El Filtro Idioma persiste las palabras de los clientes, marcando de que idioma era el artículo original. Cuando recibe la confirmación de que esa palabra se encontró para ambos idiomas, puede enviarla al handler. Al llegar el EOF, se puede eliminar de la persistencia todas las palabras guardadas para el cliente.

El Top Parcial guarda la cantidad de URLs por cada palabra que recibe, el cual será un top total de la palabra para ese cliente específico, ya que el hashing se dividirá tomando esos dos campos en cuenta. Una vez recibido el EOF, se calcula el Top Parcial con N elementos y enviarlas al Join Top Total, para poder calcular el top final que se le entrega al cliente.

El Contador persiste la cantidad de palabras únicas por URL para los artículos de años superiores a 2020, y guarda en memoria el número de URLs y número de palabras totales para los artículos de años anteriores. Al llegar el EOF, calcula el promedio con los valores guardados en memoria, y empieza a enviar aquellos datos persistidos que superan la cantidad de palabras del promedio.



[Figura 11] Diagrama de despliegue

En la figura 11 se puede ver la multiplicidad de los componentes mediante bloques que contienen workers individuales por cada uno. Cada bloque agrupa instancias de una misma función.

El cliente envía artículos al Gateway mediante HTTP. La entrega de los resultados de las queries se realiza mediante un stream TCP. Los canales de entrada y salida deben poder asociarse con cada cliente que interactúa con el sistema.

El diagrama especifica la organización por grupos y la cantidad variable de instancias, sin fijar un número ya que son variables mediante variables de entorno. Los storages locales son accesibles sólo por los componentes más cercanos a ellos.

Tamaño y rendimiento

El dataset analizado ocupa unos 47 GB entre inglés y francés (~10 millones de artículos). El Gateway descarta las columnas que no se usan, lo que reduce el volumen antes de entrar al sistema. A partir de ahí, el costo dominante no es el tamaño de los datos sino la cantidad de mensajes: las consultas que trabajan con palabras generan aproximadamente del orden de 500 millones de mensajes por cliente, que se reducen teniendo en cuenta sólo las palabras únicas y sacando las stopwords.

Por eso buscamos aprovechar al máximo los beneficios de distribuir el cómputo. El estado que cada etapa debe retener es acotado y se persiste en disco. La Query 2 es la excepción: el payload son imágenes, y su cuello de botella es el sistema externo, que se mitiga guardando las imágenes ya descargadas. Con varios clientes en paralelo, tráfico y estado se multiplican, aislados por ClientID, y se escala agregando máquinas e instancias del tipo de nodo saturado.

Tabla de contribuciones

Alumno	Tareas
Batemarco Joaquin	Implementar flujo de querys 1 y 3; Implementar Client
Braunstein Benicio	Implementar flujo de querys 2 y 4; Implementar Handler
Lynch Bautista	Implementar flujo de query 5; Implementar Gateway